① Метод Гаусса с выбором главного элемента

В отличии от обычного метода Гаусса, на каждом шаге выбирается элемент, с наибольшим по модулю значением.

Это позволяет:

1) В ходе алгоритма проверить, возможно ли решить систему (проверка, что $\max\limits_{m \geq k+1} |a_{mk}| > 0$)

2) Избежать ошибок из-за больших значений float.

② Метод LU-разложения

Th Если все Δ_k матрицы A отличны от 0, то $\exists$ LU-разложение: $A = LU$, где L-нижнетреугольная, U-верхнетреугольная.

▷ Для $n=1$ утверждение, очевидно, верное. Пусть оно верно для $(n-1)$.

Рассмотрим $A_{n \times n}$

Пусть $A_{n \times n} = \begin{Vmatrix} a & \vec{b}^T \\ \vec{c} & B \end{Vmatrix}$ = (попробуем представить в нужном виде) $= \begin{Vmatrix} a & \vec{0}^T \\ \vec{c} & L \end{Vmatrix} \begin{Vmatrix} 1 & \frac{\vec{b}^T}{a} \\ \vec{0} & \tilde{U} \end{Vmatrix} = \begin{Vmatrix} a & \vec{b}^T \\ \vec{c} & \frac{\vec{c}\vec{b}^T}{a} + L\tilde{U} \end{Vmatrix}$

$S = L\tilde{U} = B - \frac{\vec{c}\vec{b}^T}{a}$

$\Delta_{k+1} = a \det L_k \cdot 1 \cdot \det \tilde{U}_k = a \det S_k = a\Delta_k^S$

$\Delta_{k+1} \neq 0 \Rightarrow \Delta_k^S \neq 0 \Rightarrow$ для S существует LU-разложение $\Rightarrow$ для A существует LU-разложение. ◁

Найдём теперь метод нахождения LU-разложения:

$$A = LU = \begin{Vmatrix} l_{11} & 0 & 0 & \cdots & 0 \\ l_{21} & l_{22} & 0 & \cdots & 0 \\ l_{31} & l_{32} & l_{33} & \cdots & 0 \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ l_{n1} & l_{n2} & l_{n3} & \cdots & l_{nn} \end{Vmatrix} \cdot \begin{Vmatrix} u_{11} & u_{12} & u_{13} & \cdots & u_{1n} \\ 0 & u_{22} & u_{23} & \cdots & u_{2n} \\ 0 & 0 & u_{33} & \cdots & u_{3n} \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ 0 & 0 & 0 & \cdots & u_{nn} \end{Vmatrix} \Rightarrow$$

$$\Rightarrow a_{ij} = \sum_{k=1}^{n} l_{ik} u_{kj}$$

$l_{ik}=0$ при $k>i$, $u_{kj}=0$ при $j<k$ $\Rightarrow$ $a_{ij}=\sum\limits_{k=1}^{\min(i,j)} l_{ik}u_{kj}$

Будем строить U так, чтобы $u_{kk}=0$ (это очевидно можно сделать с теми же условиями)

1) $j=1$, $i\geq 1$ - строим первый столбец L

$a_{i1}=\sum\limits_{k=1}^{1} l_{ik}u_{k1}=l_{i1}$

2) $i=1$, $j>1$ - строим первую строчку U

$a_{1j}=\sum\limits_{k=1}^{1} l_{1k}u_{kj}=l_{11}u_{1j} \Rightarrow u_{1j}=\frac{a_{1j}}{l_{11}}$

Предположим, что на (m)-ом шаге построено (m) столбцов L и (m-1) строк U.

1) $j=m$, $i\geq m$ - строим m-ый столбец L

$a_{im}=\sum\limits_{k=1}^{m} l_{ik}u_{km}=\underbrace{\sum\limits_{k=1}^{m-1} l_{ik}u_{km}}_{\text{известно}}+l_{im}\underbrace{u_{mm}}_{=1} \Rightarrow l_{im}=a_{im}-\sum\limits_{k=1}^{m-1} l_{ik}u_{km}$

2) $i=m$, $j>i$ - строим m-ую строку U:

$a_{mj}=\sum\limits_{k=1}^{m} l_{mk}u_{kj}=\sum\limits_{k=1}^{m-1} l_{mk}u_{kj}+l_{mm}u_{mj} \Rightarrow u_{mj}=\frac{a_{mj}-\sum\limits_{k=1}^{m-1} l_{mk}u_{kj}}{l_{mm}}$

③ Метод Якоби

Пусть A - такова, что её диагонали не содержит нулевых элементов.

$A=D-E-F$, где D - только диагональные элементы A, E - только поддиагональные, F - только наддиагональные.

$$\begin{cases} Dx^*-Ex^*-Fx^*=b \\ Dx_{k+1}=(E+F)x_k+b \end{cases}$$

$De_{k+1}=(E+F)e_k$ ($e_k=x^*-x_k$ - ошибка)

Тогда метод сходится, если $\|D^{-1}(E+F)\|<1$ (это достаточное условие, не необходимое)

$D^{-1}=\begin{Vmatrix} \frac{1}{a_{11}} & & 0 \\ & \frac{1}{a_{22}} & \\ 0 & & \ddots & \frac{1}{a_{nn}} \end{Vmatrix}$ $\Rightarrow$ Можно легко посчитать оценку погрешности.

$|e_{k+1}|\leq q|e_k|$, где $q=\|D^{-1}(F+E)\|$

$$|e_k| = |x^* - x_k| = |x^* - x_{k+1} + x_{k+1} - x_k| \le |e_{k+1}| + |x_{k+1} - x_k|$$

$$|e_{k+1}|(1-q) \le q|x_{k+1} - x_k|$$

$$|e_{k+1}| \le \frac{q}{1-q}|x_{k+1} - x_k|$$ - эта оценка достаточно грубая

$$x_{k+1}^i = \left(b^i - \sum_{j \ne i} a_{ij} x_k^j\right) / a_{ii}$$

④ Метод Зейделя

То же самое, что метод Якоби, но учитываются построенные на текущем шаге компоненты x_{k+1}

$$x_{k+1}^i = \left(b^i - \sum_{j=1}^{i-1} a_{ij} x_{k+1}^j - \sum_{j=i+1}^{n} a_{ij} x_k^j\right)$$

⑤ SOR

$$x_{k+1} = x_k + \omega(x_k^S - x_k)$$

ω - параметр релаксации.

По сути здесь мы поправляем метод Зейделя.

⑥ Метод градиентного спуска

Пусть $A^T = A$, $A > 0$.

Рассмотрим $f(x) = \frac{1}{2} x^T A x - b^T x$

$\nabla f = Ax - b \Rightarrow$ решение исходной системы - стационарная

$\nabla \nabla^T f = A > 0 \Rightarrow f$ - строго выпукла вверх $\Rightarrow$ стационарная всегда минимум.

Пусть есть x_k. Выберем x_{k+1}: $x_{k+1} = x_k + dp$, $|p| = 1$

$$f(x_{k+1}) = f(x_k + dp) = f(x_k) + (\nabla f)^T dp + \bar{o}(d)$$

$(\nabla f)^T p$ - минимально $\Rightarrow p = -\frac{(\nabla f)}{|\nabla f|} \Rightarrow f(x_{k+1}) = f(x_k) - d\nabla f + \bar{o}(d)$

$x_{k+1} = x_k - \alpha \nabla f = x_k - \alpha (Ax_k - b) = x_k + \alpha r_k$ ($r_k = b - Ax_k$ – невязка)

Выберем на каждом шаге α_k так, чтобы $f(x_k + \alpha r_k)$ было минимальным

$$f(x_k + \alpha r_k) = \frac{1}{2}(x_k + \alpha r_k)^T A (x_k + \alpha r_k) - b^T (x_k + \alpha r_k) = \frac{1}{2} x_k^T A x_k - b^T x_k +$$
$$+ \alpha r_k^T A x_k + \frac{\alpha^2}{2} r_k^T A r_k - \alpha b^T r_k$$

$$\frac{\partial}{\partial \alpha} f(x_k + \alpha r_k) = 0 \Rightarrow r_k^T A x_k - b^T r_k + \alpha r_k^T A r_k = 0 \Rightarrow$$
$$\Rightarrow \alpha = -\frac{(x_k^T A - b^T) r_k}{r_k^T A r_k} = \frac{r_k^T r_k}{r_k^T A r_k}$$ – на каждом шаге оптимально выбирать такой α_k.

④ Метод минимальных невязок

$x_{k+1} = x_k + \alpha_k r_k$

α_k выбираем так, чтобы минимизировать $|r_{k+1}| = |b - Ax_{k+1}|$

$$r_{k+1} = b - Ax_k - \alpha_k A r_k = r_k - \alpha_k A r_k$$
$$\frac{1}{2}|r_{k+1}|^2 = \frac{1}{2}(r_k - \alpha_k A r_k, r_k - \alpha_k A r_k) = \frac{1}{2}(r_k, r_k) + \frac{\alpha_k^2}{2}(Ar_k, Ar_k) - \frac{2}{2}(r_k, \alpha_k A r_k)$$

$$\min \Rightarrow \alpha_k (Ar_k)^T (Ar_k) - (r_k, Ar_k) = 0$$

$$\alpha_k = \frac{r_k^T A r_k}{(Ar_k)^T (Ar_k)}$$

⑧ Метод сопряжённых градиентов и стабилизированный метод беспорядочных градиентов.

В методе градиентного спуска:

$f(x+\alpha p+\beta q) = f(x) + \alpha p^T(Ax-b) + \beta q^T(Ax-b) + \frac{\alpha^2}{2} p^TAp + \frac{\beta^2}{2} q^TAq + \alpha\beta p^TAq$

Из-за последнего слагаемого теряются оптимизации, достигнутые на предыдущем шаге.

$A = A^T, A>0$. Тогда $(x,y)_A = x^TAy$ - скалярное произведение

Сопряжённые вектора $(p,q)_A = 0$ (тогда смешанное слагаемое зануляется)

Тогда если выбирать такие направления для спуска, то минимизация вдоль одного не мешает уже проделанной минимизации вдоль другого.

Предположим, что мы каким-то образом построили набор n попарно сопряжённых направлений $p_0, p_1, \dots p_{n-1}$. $(p_i^TAp_j = 0)$

$x_{k+1} = x_k + \alpha_k p_k$

$f(x_{k+1}) = f(x_k + \alpha_k p_k) = \frac{1}{2}(x_k + \alpha_k p_k)^TA(x_k + \alpha_k p_k) - b^T(x_k + \alpha_k p_k) =$

$= \frac{1}{2} x_k^TAx_k - b^Tx_k + \alpha_k p_k^TAx_k + \frac{\alpha_k^2}{2} p_k^TAp_k - b^T\alpha_k p_k$

$= f(x_k) + \alpha_k (Ax_n - b)^Tp_k + \frac{\alpha_k^2}{2} p_k^TAp_k = f(x_k) - \alpha_k r_k^Tp_k + \frac{\alpha_k^2}{2} p_k^TAp_k$

$\frac{d}{d\alpha_k} f(x_{k+1}) = -r_k^Tp_k + \alpha_k p_k^TAp_k = 0$

$\alpha_k = \frac{(r_k \cdot p_k)}{(p_k \cdot Ap_k)}$

$e_k = x^* - x_k$ - ошибка

$Ae_k = Ax^* - Ax_k = b - Ax_k = r_k$ $\Rightarrow r_k = Ae_k$

$r_{k+1} = b - Ax_{k+1} = b - Ax_k - \alpha_k Ap_k = r_k - \alpha_k Ap_k \Rightarrow$

$\Rightarrow p_k^Tr_{k+1} = p_k^Tr_k - \alpha_k p_k^TAp_k = p_k^Tr_k - p_k^Tr_k = 0$

То есть оптимальный шаг удовлетворяет $p_k^Tr_{k+1} = 0$

$p_k^TAe_{k+1} = 0$

$e_{k+2} = e_{k+1} - \alpha_{k+1} p_{k+1} \Rightarrow p_k^T A e_{k+2} = p_k^T A (e_{k+1} - \alpha_{k+1} p_{k+1}) =$

$= \underbrace{p_k^T r_{k+1}}_{=0 \text{ (доказано выше)}} - \alpha_{k+1} \underbrace{p_k^T A p_{k+1}}_{=0 \text{ (сопр)}}$

Тогда $p_k^T A e_{k+2} = 0$.

После n шагов: $p_i^T A e_n = 0 \Rightarrow A e_n = 0$ (p_i образуют базис) $\Rightarrow$

$\Rightarrow e_n = 0 = x^* - x_n$, то есть алгоритм решает систему за n шагов.

Теперь разберёмся как строить p_i (можно методом Грама-Шмидта, но это долго)

Положим $p_{k+1} = r_{k+1} + \beta_k p_k$

$p_{k+1}^T A p_k = 0 \Rightarrow r_{k+1}^T A p_k + \beta_k p_k^T A p_k = 0$

$\beta_k = -\frac{(r_{k+1} \cdot A p_k)}{(p_k \cdot A p_k)}$

$r_{k+1} = r_k - \alpha_k A p_k \Rightarrow A p_k = \frac{r_k - r_{k+1}}{\alpha_k}$

$r_{k+1}^T A p_k = r_{k+1}^T \frac{r_k - r_{k+1}}{\alpha_k} = \frac{1}{\alpha_k}(r_{k+1}^T r_k - r_{k+1}^T r_{k+1})$

Для метода сопряжённых градиентов невязки попарно ортогональны:

$r_{k+1}^T r_k = 0 \Rightarrow r_{k+1}^T A p_k = -\frac{r_{k+1}^T r_{k+1}}{\alpha_k}$

$\beta_k = \frac{r_{k+1}^T r_{k+1}}{\alpha_k p_k^T A p_k}$, $\alpha_k = \frac{p_k^T r_k}{p_k^T A p_k} \Rightarrow$

$\Rightarrow \beta_k = \frac{r_{k+1}^T r_{k+1}}{p_k^T r_k} \frac{p_k^T A p_k}{p_k^T A p_k} = \frac{r_{k+1}^T r_{k+1}}{p_k^T r_k}$ ($p_k = r_k + \beta_{k-1} p_{k-1} \Rightarrow p_k^T r_k = r_k^T r_k$).

$p_0 = b - A x_0 = r_0$?

$\alpha_k = \frac{p_k^T r_k}{p_k^T A p_k}$, $x_{k+1} = x_k + \alpha_k p_k$

$r_{k+1} = r_k - \alpha_k A p_k$

$\beta_k = \frac{r_{k+1}^T r_{k+1}}{r_k^T r_k}$, $p_{k+1} = r_{k+1} + \beta_k p_k$

Стабилизированный метод бисопряжённых градиентов не выведу